ECE-Υ322 Πιθανοθεωρία και Στατιστική

Εβδομάδα 6: Συνεχή Πρότυπα Κατανομών

Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών
Πανεπιστήμιο Πατρών

2026–2027

vasileios.papastefanopoulos@upatras.gr

Πού μείναμε, και τι ακολουθεί

Χτίσαμε τα διακριτά πρότυπα και τη διαδικασία Poisson: το πλήθος γεγονότων σε χρόνο t είναι Poisson(λt).

Σήμερα περνάμε στα *συνεχή* πρότυπα: επτά κατανομές, καθεμία από τον μηχανισμό της: ομοιόμορφη, εκθετική, Gamma, Beta, κανονική, λογαριθμοκανονική, Weibull.

Περιεχόμενα

1. Η ομοιόμορφη
2. Η εκθετική
3. Η Gamma
4. Η Beta
5. Η κανονική
6. Η λογαριθμοκανονική
7. Ο ρυθμός αστοχίας και η Weibull
8. Αξιοπιστία συστημάτων
9. Πώς διαλέγουμε πρότυπο
10. Σύνοψη

Η ομοιόμορφη

uniform distribution

Ομοιόμορφη: πόσο θα περιμένετε

Το λεωφορείο περνάει από τη στάση κάθε 10 λεπτά, ακριβώς στην ώρα του. Φτάνετε κάποια στιγμή χωρίς να κοιτάξετε ρολόι. Πόσο θα περιμένετε;

- Ο χρόνος αναμονής X είναι με βεβαιότητα από 0 ως 10 λεπτά: $X \in [0, 10]$.
- Δεν έχουμε όμως κανέναν λόγο να πούμε ότι η άφιξή σας προτιμά το τρίτο λεπτό από το έβδομο. Όλες οι στιγμές είναι εξίσου εύλογες.
- Προσοχή στη διατύπωση: δεν λέμε «κάθε τιμή έχει την ίδια πιθανότητα», γιατί κάθε μεμονωμένη τιμή έχει πιθανότητα 0. Αυτό που είναι σταθερό είναι η **πυκνότητα**.

Τι μοντελοποιεί

Η πιθανότητα να πέσει μια τιμή σε ένα κομμάτι του $[a, b]$, όταν **καμία θέση δεν προτιμάται**.

Το ύψος βγαίνει μόνο του

«Ομοιόμορφη» σημαίνει ότι η **πυκνότητα** είναι σταθερή μέσα στο διάστημα: η καμπύλη f είναι μια οριζόντια ευθεία σε κάποιο ύψος c, και μηδέν παντού έξω από αυτό. Πόσο είναι το c δεν το ξέρουμε ακόμη, αλλά δεν χρειάζεται καν να το διαλέξουμε.

- Πιθανότητα, στη συνεχή περίπτωση, είναι **εμβαδόν** κάτω από την f. Το συνολικό εμβαδόν οφείλει να είναι 1.
- Εδώ το σχήμα είναι ορθογώνιο με βάση $b-a$ και ύψος c, άρα εμβαδόν $c\,(b-a)$:

$$c\,(b-a) = 1 \quad \Longrightarrow \quad c = \frac{1}{b-a}.$$

- Δεν διαλέξαμε το ύψος. Μας το επέβαλε η κανονικοποίηση.

Προσοχή: το c *δεν* είναι πιθανότητα. Για το λεωφορείο είναι $1/(10-0) = 0.1$ ανά λεπτό, αλλά σε διάστημα πλάτους 0.1 θα ήταν 10: μια πυκνότητα επιτρέπεται να ξεπερνά το 1, ένα εμβαδόν όχι.

Ένα σημείο έχει πιθανότητα 0, όλο το διάστημα 1

Η πυκνότητα του λεωφορείου είναι ορθογώνιο με ύψος 0.1, άρα η πιθανότητα μιας λωρίδας είναι **πλάτος** $\times$ **ύψος**. Κόβουμε το $[0, 10]$ σε όλο και στενότερες λωρίδες:

πλάτος (λεπτά)	μία λωρίδα	όλες οι λωρίδες
1	$1 \times 0.1 = 0.1$	$10 \times 0.1 = 1$
0.1	$0.1 \times 0.1 = 0.01$	$100 \times 0.01 = 1$
0.01	$0.01 \times 0.1 = 0.001$	$1000 \times 0.001 = 1$
$\to 0$	$\to 0$	1

Μία λωρίδα στενεύει ως ένα σημείο και η πιθανότητά της πάει στο 0, ενώ το ύψος μένει 0.1: $\mathbb{P}(X = 5) = 0 \times 0.1 = 0$. **Όλες μαζί** δίνουν πάντα 1, γιατί όσο στενεύουν τόσο πληθαίνουν. Γι΄ αυτό προσθέτουμε λωρίδες, δηλαδή εμβαδόν, και όχι σημεία: όσα μηδενικά κι αν προσθέσουμε, δίνουν 0.

Ορισμός και συνάρτηση κατανομής

Ομοιόμορφη κατανομή, $X \sim \mathcal{U}(a, b)$

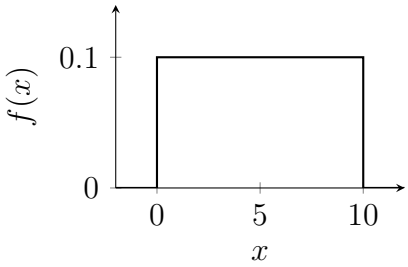
$$f(x) = \begin{cases} \dfrac{1}{b-a}, & a \le x \le b \\ 0, & \text{αλλού} \end{cases}$$

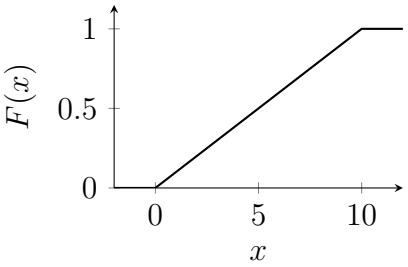
Η αθροιστική είναι το εμβαδόν κάτω από την πυκνότητα ως το x, εδώ ορθογώνιο, βάση επί ύψος:

$$F(x) = \int_a^x \frac{1}{b-a}\, dt = \frac{x-a}{b-a}, \qquad a \le x \le b,$$

με $F(x) = 0$ πριν από το a και $F(x) = 1$ μετά το b. Ανάμεσα ανεβαίνει **γραμμικά**: ίσα διαστήματα, ίση πιθανότητα. Για το λεωφορείο, $F(x) = x/10$: αναμονή το πολύ 2.5 λεπτά με πιθανότητα 25%, το πολύ 5 λεπτά με 50%.

Η πυκνότητα και η κατανομή, μαζί





Σταθερή πυκνότητα αριστερά, ευθεία κατανομή δεξιά.

Μέση τιμή και διασπορά της ομοιόμορφης

$$\mathbb{E}[X] = \frac{a+b}{2}, \qquad \mathrm{Var}(X) = \frac{(b-a)^2}{12}$$

Βγαίνουν από τους ορισμούς, $\mathbb{E}[X] = \int_a^b x\, f(x)\, dx$ και $\mathbb{E}[X^2] = \int_a^b x^2 f(x)\, dx$ με $f(x) = 1/(b-a)$, και από τον υπολογιστικό τύπο $\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

Για το λεωφορείο, με $a = 0$ και $b = 10$ λεπτά, $\mathbb{E}[X] = (0+10)/2 = 5$ λεπτά, $\mathrm{Var}(X) = 10^2/12 = 8.333333$ και $\sigma = \sqrt{8.333333} = 2.886751$ λεπτά.

Η μέση τιμή είναι το **μέσο του διαστήματος**. Η διασπορά εξαρτάται μόνο από το *πλάτος* $b - a$: μετατόπιση του διαστήματος δεν την αλλάζει.

Σύνοψη της ομοιόμορφης

μηχανισμός	καμία προτίμηση μέσα σε ένα διάστημα
παράμετροι	$a < b$
$f(x)$	$1/(b-a)$ στο $[a,b]$, αλλιώς 0
$F(x)$	$(x-a)/(b-a)$ (κλειστός τύπος)
$\mathbb{E}[X]$	$(a+b)/2$
$\mathrm{Var}(X)$	$(b-a)^2/12$

Η εκθετική

exponential distribution

Εκθετική: πόσο θα περιμένετε ως το επόμενο

Σε έναν δρομολογητή φτάνουν πακέτα με σταθερό μέσο ρυθμό $\lambda = 3$ ανά δευτερόλεπτο, ανεξάρτητα το ένα από το άλλο. Μόλις τώρα ήρθε ένα. **Πόσο θα περιμένουμε ως το επόμενο;**

Είναι η **γεωμετρική** του συνεχούς χρόνου: η γεωμετρική μετράει δοκιμές ως το πρώτο γεγονός, εδώ μετράμε χρόνο. Και σε αντίθεση με το λεωφορείο, **δεν υπάρχει ανώτατο όριο**: το επόμενο πακέτο μπορεί να αργήσει όσο θέλει.

Ζητάμε την **κατανομή** του χρόνου T ως την επόμενη άφιξη, και θα την *παραγάγουμε* από όσα ξέρουμε για το πλήθος των αφίξεων.

Τι μοντελοποιεί

Η πιθανότητα η **απόσταση ανάμεσα σε διαδοχικά γεγονότα** μιας διαδικασίας Poisson να πέσει σε ένα διάστημα.

Το σχέδιο: πρώτα η F, μετά η f

Στα διακριτά πρότυπα πήγαμε κατευθείαν στη μάζα $\mathbb{P}(X = k)$: τη βρίσκαμε σε ένα συγκεκριμένο παράδειγμα και μετά τη γενικεύαμε. Εδώ αυτό δεν γίνεται, γιατί ένα σημείο έχει πιθανότητα 0: $\mathbb{P}(T = t) = 0$ για κάθε t.

Πιθανότητα έχουν μόνο τα **διαστήματα**. Γι' αυτό βρίσκουμε πρώτα την **αθροιστική** $F(t) = \mathbb{P}(T \leq t)$, και από αυτήν την **πυκνότητα**, παραγωγίζοντας. Στην πράξη ευκολότερη είναι η αντίθετη πιθανότητα, η **ουρά** $\mathbb{P}(T > t)$:

$$\mathbb{P}(T > t) \longrightarrow F(t) = 1 - \mathbb{P}(T > t) \longrightarrow f(t) = F'(t)$$

Στην ομοιόμορφη κάναμε το αντίστροφο: η ιστορία μας έδωσε κατευθείαν το σχήμα της f, σταθερό, και από αυτήν βγάλαμε την F.

Το κλειδί: από τον χρόνο στο πλήθος

Δεν ξέρουμε τίποτα ακόμη για χρόνους. Ξέρουμε όμως τα πάντα για **πλήθη**: το πλήθος N των αφίξεων σε διάστημα $[0, t]$ ακολουθεί Poisson(λt).

Η γέφυρα είναι μία πρόταση:

Το γεγονός «$T > t$», δηλαδή «περιμένουμε πάνω από t», είναι *ακριβώς* το γεγονός «κανένα πακέτο δεν ήρθε στο $[0, t]$»:

$$\mathbb{P}(T > t) = \mathbb{P}(N = 0).$$

Τα δύο είναι το ίδιο γεγονός γραμμένο αλλιώς: αν είχε φτάσει έστω ένα μέσα στο $[0, t]$, ο χρόνος αναμονής θα ήταν το πολύ t. Και αντίστροφα. Άρα μια ερώτηση για *χρόνο* μετατράπηκε σε ερώτηση για *πλήθος*, που ξέρουμε να απαντήσουμε.

Ο υπολογισμός της ουράς $\mathbb{P}(T > t)$

Το πλήθος N των αφίξεων στο $[0, t]$ ακολουθεί Poisson(λt), δηλαδή έχει μάζα

$$\mathbb{P}(N = k) = \frac{e^{-\lambda t}(\lambda t)^k}{k!}.$$

Εμάς μας ενδιαφέρει το **κανένα**, δηλαδή $k = 0$:

$$\mathbb{P}(N = 0) = \frac{e^{-\lambda t}(\lambda t)^0}{0!} = \frac{e^{-\lambda t} \cdot 1}{1} = e^{-\lambda t}, \qquad \text{αφού } (\lambda t)^0 = 1 \text{ και } 0! = 1.$$

Και με τη γέφυρα $\mathbb{P}(T > t) = \mathbb{P}(N = 0)$ που στήσαμε πριν:

$$\mathbb{P}(T > t) = e^{-\lambda t}.$$

Η αθροιστική όμως ρωτάει το *αντίθετο*, $F(t) = \mathbb{P}(T \le t)$. Τα δύο γεγονότα είναι συμπληρωματικά, οπότε

$$F(t) = \mathbb{P}(T \le t) = 1 - \mathbb{P}(T > t) = 1 - e^{-\lambda t}.$$

Και η πυκνότητα

Έχουμε την F, οπότε την πυκνότητα την παίρνουμε παραγωγίζοντας. Το 1 είναι σταθερά και σβήνει, και στο $e^{-\lambda t}$ εφαρμόζουμε τον κανόνα της αλυσίδας, που κατεβάζει το $-\lambda$:

$$f(t) = \frac{d}{dt}\left(1 - e^{-\lambda t}\right) = 0 - e^{-\lambda t} \cdot (-\lambda) = \lambda e^{-\lambda t}, \qquad t \geq 0.$$

Έλεγχος ότι είναι πυκνότητα: το ολοκλήρωμά της σε όλο το πεδίο πρέπει να κάνει 1.

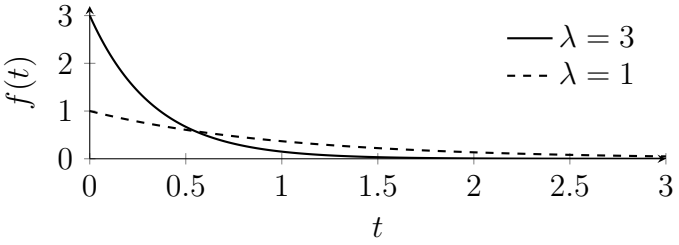
$$\int_0^\infty \lambda e^{-\lambda t}\, dt = \Big[-e^{-\lambda t}\Big]_0^\infty = 0 - (-1) = 1.$$

Ο ορισμός, και δύο ρυθμοί σε ένα σχήμα

Εκθετική κατανομή

$$f(t) = \lambda e^{-\lambda t} \ (t \geq 0), \qquad F(t) = 1 - e^{-\lambda t}, \qquad \mathbb{P}(T > t) = e^{-\lambda t}$$

Το λ είναι ο **ρυθμός**, σε γεγονότα ανά μονάδα χρόνου, και γράφουμε $T \sim Exp(\lambda)$. Η πυκνότητα είναι **φθίνουσα**: όσο μεγαλύτερη μια αναμονή, τόσο σπανιότερη, αφού θέλει τόσο χρόνο χωρίς κανένα γεγονός. Μεγαλύτερο λ, μικρότερες αναμονές.



Μέση τιμή και διασπορά της εκθετικής

$$\mathbb{E}[T] = \frac{1}{\lambda}, \qquad \mathrm{Var}(T) = \frac{1}{\lambda^2}, \qquad \sigma = \frac{1}{\lambda} = \mathbb{E}[T]$$

Βγαίνουν από τους ορισμούς, $\mathbb{E}[T] = \int_0^\infty t\,\lambda e^{-\lambda t}\,dt$ και $\mathbb{E}[T^2] = \int_0^\infty t^2\,\lambda e^{-\lambda t}\,dt$, με ολοκλήρωση κατά μέρη.

Με $\lambda = 3$ πακέτα ανά δευτερόλεπτο, $\mathbb{E}[T] = 1/3 = 0.333333$ δευτερόλεπτα, $\mathrm{Var}(T) = 1/9 = 0.111111$ και $\sigma = 0.333333$ δευτερόλεπτα. Οι μονάδες συμφωνούν: το λ είναι «ανά δευτερόλεπτο», άρα το $1/\lambda$ είναι δευτερόλεπτα.

Η τυπική απόκλιση βγαίνει **ίση με τη μέση τιμή**: ο χρόνος αναμονής είναι εξαιρετικά απρόβλεπτος.

Οι μικρές αναμονές είναι πιθανότερες

Η πυκνότητα $f(t) = \lambda e^{-\lambda t}$ είναι **φθίνουσα**, γιατί η παράγωγός της είναι αρνητική για κάθε t:

$$f'(t) = \frac{d}{dt}\left(\lambda e^{-\lambda t}\right) = \lambda \cdot e^{-\lambda t} \cdot (-\lambda) = -\lambda^2 e^{-\lambda t} < 0.$$

Με $\lambda = 3$: $f(0) = 3e^0 = 3$ και $f(1) = 3e^{-3} = 0.149361$.

Το ίδιο με πιθανότητες. Ένα διάστημα 0.1 δευτερολέπτων που αρχίζει στο t:

$$\begin{aligned}\mathbb{P}(t < T \le t + 0.1) &= F(t + 0.1) - F(t) = \left(1 - e^{-3(t+0.1)}\right) - \left(1 - e^{-3t}\right) \\ &= e^{-3t} - e^{-3t}e^{-0.3} = e^{-3t}\left(1 - e^{-0.3}\right).\end{aligned}$$

Δύο διαστήματα με το ίδιο πλάτος:

$$\begin{aligned}t = 0: &\quad e^0\left(1 - e^{-0.3}\right) = 1 \cdot 0.259182 = 0.259182, \\ t = 1: &\quad e^{-3}\left(1 - e^{-0.3}\right) = 0.049787 \cdot 0.259182 = 0.012904.\end{aligned}$$

Γιατί οι μικρές αναμονές είναι πιθανότερες;

Στον Γκρινιάρη ρίχνουμε το ζάρι ώσπου να φέρουμε έξι, για να βγει το πιόνι, και τότε **σταματάμε**. Σε ποια ρίψη έρχεται το πρώτο έξι;

ρίψη	τι χρειάζεται	πιθανότητα
1η	έξι	$1/6 = 0.166667$
2η	όχι έξι, μετά έξι	$(5/6)(1/6) = 0.138889$
3η	όχι έξι, όχι έξι, μετά έξι	$(5/6)(5/6)(1/6) = 0.115741$

Κάθε ρίψη φέρνει έξι με την *ίδια* πιθανότητα $1/6$: αν ρίχναμε πάντα τρεις φορές, το έξι θα ερχόταν εξίσου συχνά σε καθεμία. Τις πιθανότητες τις μικραίνει το **σταμάτημα**: η δεύτερη ρίψη γίνεται μόνο αν η πρώτη δεν φέρει έξι.

Η ρίψη του πρώτου έξι ακολουθεί τη **γεωμετρική**, και η εκθετική είναι το ίδιο σε συνεχή χρόνο: κάθε 0.1 δευτερόλεπτα είναι μια «ρίψη» που φέρνει πακέτο με πιθανότητα 0.259182, και σταματάμε στο πρώτο.

Πόσο αντέχει ακόμη ένας εξυπηρετητής;

Ένας εξυπηρετητής έχει εκθετικό χρόνο ζωής, με $\mathbb{E}[T] = 8000$ ώρες, και δουλεύει ήδη 5000 ώρες χωρίς πρόβλημα. Ποια είναι η πιθανότητα να αντέξει 4000 ώρες *ακόμη*;

Από τον ορισμό $\mathbb{P}(A \mid B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$, με τομή απλώς το $\{T > 9000\}$ (όποιος περνά τις 9000 έχει περάσει και τις 5000), και την ουρά $\mathbb{P}(T > t) = e^{-\lambda t}$:

$$\mathbb{P}(T > 9000 \mid T > 5000) = \frac{\mathbb{P}(\{T > 9000\} \cap \{T > 5000\})}{\mathbb{P}(T > 5000)} = \frac{\mathbb{P}(T > 9000)}{\mathbb{P}(T > 5000)}$$
$$= \frac{e^{-\lambda \cdot 9000}}{e^{-\lambda \cdot 5000}} = e^{-\lambda(9000-5000)} = e^{-\lambda \cdot 4000}.$$

Με $\lambda = 1/\mathbb{E}[T] = 1/8000$:

$$e^{-\lambda \cdot 4000} = e^{-4000/8000} = e^{-0.5} = 0.606531.$$

Η αμνησία: η ηλικία δεν μετράει

Για έναν *καινούριο* εξυπηρετητή, $\mathbb{P}(T > 4000) = e^{-\lambda \cdot 4000}$: **ο ίδιος αριθμός**. Και γενικά, με τα ίδια βήματα, $e^{-\lambda(s+t)}/e^{-\lambda s} = e^{-\lambda t}$ για κάθε ηλικία s και κάθε διάρκεια t. Η ιδιότητα λέγεται **αμνησία** (memorylessness):

$$\mathbb{P}(T > s + t \mid T > s) = \mathbb{P}(T > t)$$

Η υπόλοιπη ζωή δεν εξαρτάται από το πόσο έχει ήδη δουλέψει.

Η διαίσθηση όμως λέει: «δουλεύει ήδη 5000 ώρες, έχει φθαρεί, άρα έχει λιγότερες πιθανότητες από ένα καινούριο». Για ένα πραγματικό μηχάνημα αυτό συχνά ισχύει. Η εκθετική είναι πρότυπο **χωρίς φθορά**, άρα όπου υπάρχει φθορά είναι **λάθος πρότυπο**.

Πότε ισχύει η αμνησία, και πότε όχι

Ένα εξάρτημα χωρίς μνήμη είναι, κάθε στιγμή, εξίσου καλό με ένα καινούριο. Δεν φθείρεται και δεν στρώνει: περιμένει ένα εξωτερικό συμβάν που έρχεται με σταθερό ρυθμό.

Ισχύει

Το γεγονός έρχεται από έξω:

- ραδιενεργός διάσπαση
- σωματίδιο που χτυπά κύτταρο μνήμης
- άφιξη πακέτου, κλήσης, πελάτη
- υπέρταση στο δίκτυο

Δεν ισχύει

Υπάρχει φθορά, και το παλιό είναι όντως χειρότερο:

- ξήρανση πυκνωτών
- κόπωση υλικού
- ηλεκτρομετανάστευση

Σύνοψη της εκθετικής

μηχανισμός	αναμονή σε διαδικασία Poisson
στα διακριτά	γεωμετρική
παράμετροι	$\lambda > 0$, ο ρυθμός
$f(t)$	$\lambda e^{-\lambda t}, \quad t \geq 0$
$F(t)$	$1 - e^{-\lambda t}$ (κλειστός τύπος)
$\mathbb{E}[T]$	$1/\lambda$
$\mathrm{Var}(T)$	$1/\lambda^2$
αμνησία	$\mathbb{P}(T > s + t \mid T > s) = \mathbb{P}(T > t)$

Η υπόλοιπη ζωή δεν εξαρτάται από την ηλικία. Γι΄ αυτό η εκθετική είναι σωστό πρότυπο για τυχαία εξωτερικά συμβάντα και λάθος για φθορά.

H Gamma

Gamma distribution

Gamma: ο χρόνος ως το k-οστό πακέτο

Ο αποκωδικοποιητής δεν ξεκινά με το πρώτο πακέτο: χρειάζεται **τρία** πακέτα στη μνήμη πριν αρχίσει να παίζει. Με $\lambda = 3$ πακέτα ανά δευτερόλεπτο, πόσο θα περιμένει ο χρήστης;

Είναι η **αρνητική διωνυμική** του συνεχούς χρόνου. Εκείνη ήταν άθροισμα γεωμετρικών, και η Gamma είναι **άθροισμα εκθετικών**: $T = T_1 + T_2 + T_3$, τρεις διαδοχικές αναμονές ως το επόμενο πακέτο, που από τις υποθέσεις της διαδικασίας είναι εκθετικές με τον ίδιο ρυθμό λ και **ανεξάρτητες**. Η πρόχειρη απάντηση, «άρα πάλι εκθετική», είναι εύλογη και λανθασμένη.

Τι μοντελοποιεί

Η πιθανότητα ο **χρόνος ως το k-οστό γεγονός** μιας διαδικασίας Poisson να πέσει σε ένα διάστημα.

Το κλειδί είναι μία λέξη: σειρά

Τα τρία γεγονότα γίνονται το ένα **μετά** το άλλο, και αυτό αλλάζει τα πάντα. **Δοκιμάστε το με ένα ζάρι**, περιμένοντας το τρίτο έξι:

- Για το *πρώτο* έξι η πιθανότερη ρίψη είναι η πρώτη, όπως είδαμε στην εκθετική.
- Για το *τρίτο* όμως, το να τελειώσουμε στη ρίψη 3 απαιτεί έξι, έξι, έξι στη σειρά: $(1/6)^3 = 0.004630$.
- Στη ρίψη 10 κάθε μία σειρά είναι λιγότερο πιθανή, αλλά οι σειρές είναι **πολλές**: τα δύο πρώτα έξι χωράνε σε 36 θέσεις, και μαζί δίνουν 0.046514.
- Οι ρίψεις είναι διακριτές, οπότε η ρίψη του τρίτου έξι ακολουθεί την **αρνητική διωνυμική**, *όχι* τη Gamma: κορυφή στη 12 και στη 13, μέσος όρος $3 \times 6 = 18$.

Το ζάρι είναι εδώ μόνο για τη διαίσθηση: η κορυφή έφυγε από την αρχή επειδή περιμένουμε *στη σειρά*, όπως και τα πακέτα.

Το ίδιο, με χρόνους αντί για ρίψεις

- Για συνολικό χρόνο σχεδόν **μηδέν** θα έπρεπε *και τα τρία* πακέτα να φτάσουν ακαριαία, το ένα πίσω από το άλλο. Ένα μπορεί άνετα· τρία στη σειρά, πρακτικά ποτέ.
- Άρα η πυκνότητα κοντά στο μηδέν δεν είναι απλώς μικρή: **τείνει στο μηδέν**.
- Οι πολύ μεγάλοι χρόνοι είναι πάλι σπάνιοι, όπως πάντα.
- Ό,τι μένει αναγκαστικά ανεβαίνει σε **κορυφή στη μέση**: για τρία πακέτα στα 0.666667 δευτερόλεπτα (το βλέπουμε στο σχήμα παρακάτω), ενώ ο μέσος χρόνος είναι 1 δευτερόλεπτο. Ίδια εικόνα με το ζάρι, όπου η κορυφή ήταν στο 12 (και στο 13) και ο μέσος στο 18.

Η εκθετική ξεκινά από το *μέγιστό* της και μόνο πέφτει. Το άθροισμα ξεκινά από το μηδέν, ανεβαίνει, και μετά πέφτει. Δεν γίνεται να είναι η ίδια κατανομή.

Το σχέδιο: πάλι μέσα από το πλήθος

Ζητάμε την **κατανομή** του T, για να απαντάμε σε ερωτήσεις όπως «ποια η πιθανότητα να περιμένει πάνω από 2 δευτερόλεπτα;».

Τη βρίσκουμε γυρίζοντας στο **μέτρημα των γεγονότων**, όπως για την εκθετική: πρώτα την αθροιστική $F(t) = \mathbb{P}(T \leq t)$, και από αυτήν την $f(t) = F'(t)$.

Η ταυτότητα των ουρών

$$\mathbb{P}(T > t) = \mathbb{P}\big(N(t) \leq 2\big)$$

«Το τρίτο πακέτο *δεν* έχει έρθει ως τη στιγμή t» είναι το ίδιο γεγονός με «στο $[0, t]$ έχουν έρθει *το πολύ* 2 πακέτα».

Και το πλήθος στο $[0, t]$ το ξέρουμε: ακολουθεί Poisson(λt). Μια ερώτηση για *χρόνο* έγινε πάλι ερώτηση για *πλήθος*.

Ο τύπος της ουράς, βήμα βήμα

Βήμα 1: μεταφράζουμε το γεγονός. Το τρίτο πακέτο δεν έχει έρθει ως τη στιγμή t ακριβώς όταν στο $[0, t]$ έχουν έρθει *το πολύ δύο*:

$$\{T > t\} = \{N(t) \leq 2\} \quad \Longrightarrow \quad \mathbb{P}(T > t) = \mathbb{P}\big(N(t) \leq 2\big).$$

Βήμα 2: χωρίζουμε το «το πολύ δύο». Είναι τρία ξένα ενδεχόμενα, $N(t) = 0$, 1 ή 2, οπότε οι πιθανότητες προστίθενται:

$$\mathbb{P}\big(N(t) \leq 2\big) = \sum_{i=0}^{2} \mathbb{P}\big(N(t) = i\big).$$

Βήμα 3: βάζουμε τη μάζα της Poisson(λt).

$$\mathbb{P}(T > t) = \sum_{i=0}^{2} \frac{e^{-\lambda t}(\lambda t)^i}{i!} = e^{-\lambda t}\left(1 + \lambda t + \frac{(\lambda t)^2}{2}\right).$$

Από την ουρά στην πυκνότητα: παραγωγίζουμε

Η αθροιστική είναι το συμπλήρωμα της ουράς:

$$F(t) = 1 - \mathbb{P}(T > t) = 1 - e^{-\lambda t}\left(1 + \lambda t + \frac{\lambda^2 t^2}{2}\right).$$

Η πυκνότητα είναι η παράγωγός της, με τον κανόνα του γινομένου:

$$\begin{aligned} f(t) = F'(t) &= \lambda e^{-\lambda t}\left(1 + \lambda t + \tfrac{\lambda^2 t^2}{2}\right) - e^{-\lambda t}\left(\lambda + \lambda^2 t\right) \\ &= e^{-\lambda t}\left[\lambda + \lambda^2 t + \tfrac{\lambda^3 t^2}{2} - \lambda - \lambda^2 t\right] = \frac{\lambda^3 t^2}{2}\, e^{-\lambda t}. \end{aligned}$$

Έμεινε μόνο ο τελευταίος όρος. Τα 2 είναι το $3-1$ των πακέτων, $t^2 = t^{3-1}$ και $2 = (3-1)!$, και με $\lambda = 3$:

$$f(t) = \frac{\lambda^3\, t^{3-1}\, e^{-\lambda t}}{(3-1)!} = \frac{3^3\, t^2\, e^{-3t}}{2} = \frac{27}{2}\, t^2 e^{-3t}.$$

Η πυκνότητα

Με k πακέτα στη θέση των 3:

Κατανομή Erlang: η Gamma με *θετικό ακέραιο* k

$$f(t) = \frac{\lambda^k t^{k-1} e^{-\lambda t}}{(k-1)!}, \qquad t \geq 0$$

Η Gamma δέχεται *οποιοδήποτε* θετικό k, και με θετικό ακέραιο k, εδώ πλήθος πακέτων, παίρνει αυτή τη μορφή. Με $k = 1$ είναι η εκθετική. Η δική μας f έχει εμβαδόν 0.999997 στο $[0, 6]$, 1 μείον την ουρά.

Η αθροιστική είναι αυτή που μόλις βγάλαμε, για γενικό k:

$$F(t) = 1 - \sum_{i=0}^{k-1} \frac{e^{-\lambda t}(\lambda t)^i}{i!}.$$

Μέση τιμή και διασπορά της Gamma

$$\mathbb{E}[T] = \frac{k}{\lambda}, \qquad \mathrm{Var}(T) = \frac{k}{\lambda^2}$$

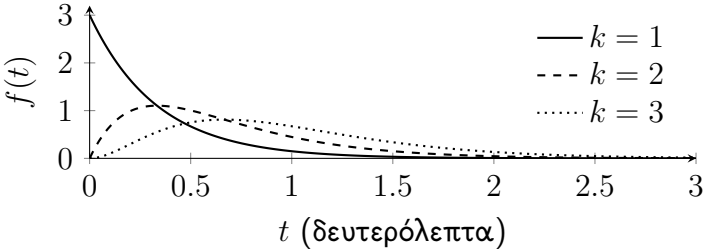
Βγαίνουν χωρίς ολοκλήρωμα, από το άθροισμα $T = T_1 + \cdots + T_k$ των k εκθετικών, όπως της αρνητικής διωνυμικής από τις γεωμετρικές. Κάθε κομμάτι έχει $\mathbb{E}[T_i] = 1/\lambda$ και $\mathrm{Var}(T_i) = 1/\lambda^2$. Οι μέσες τιμές προστίθενται πάντα, οι διασπορές επειδή τα κομμάτια είναι *ανεξάρτητα*:

$$\mathbb{E}[T] = \mathbb{E}[T_1] + \cdots + \mathbb{E}[T_k] = k \cdot 1/\lambda = k/\lambda,$$
$$\mathrm{Var}(T) = \mathrm{Var}(T_1) + \cdots + \mathrm{Var}(T_k) = k \cdot 1/\lambda^2 = k/\lambda^2.$$

Για τον αποκωδικοποιητή, με $k = 3$ και $\lambda = 3$: $\mathbb{E}[T] = 3/3 = 1$ δευτερόλεπτο, $\mathrm{Var}(T) = 3/9 = 0.333333$ και $\sigma = \sqrt{0.333333} = 0.577350$ δευτερόλεπτα.

Τρεις τιμές του k, ένα σχήμα

Δύο έλεγχοι πρώτα. Για $k = 1$ ο τύπος δίνει $\lambda^1 t^0 e^{-\lambda t}/0! = \lambda e^{-\lambda t}$, δηλαδή ξαναβρίσκουμε την **εκθετική**. Για $k = 2$ δίνει $\lambda^2 t e^{-\lambda t}/1!$, που **μηδενίζεται στο** $t = 0$, όπως ακριβώς απαιτήσαμε για δύο πακέτα στη σειρά.



Κορυφή στο 0 με ύψος 3 για $k = 1$, στο 0.333333 με 1.103638 για $k = 2$, στο 0.666667 με 0.812012 για $k = 3$: όσο περισσότερα πακέτα περιμένουμε, τόσο πιο δεξιά και πιο χαμηλά η κορυφή.

Η συνάρτηση Γάμμα: το παραγοντικό για κάθε $k > 0$

Η πυκνότητα της Gamma έχει $(k-1)!$, που ορίζεται μόνο για ακέραια k. Η συνάρτηση Γάμμα το επεκτείνει σε κάθε $k > 0$:

$$\Gamma(k) = \int_0^\infty y^{k-1} e^{-y}\, dy, \qquad k > 0$$

- **Ο κανόνας**, με ολοκλήρωση κατά παράγοντες:

$$\Gamma(k+1) = \int_0^\infty y^k e^{-y}\, dy = \underbrace{\left[-y^k e^{-y}\right]_0^\infty}_{0} + k \int_0^\infty y^{k-1} e^{-y}\, dy = k\,\Gamma(k).$$

- **Στους ακέραιους:** $\Gamma(1) = \int_0^\infty e^{-y}\, dy = 1$, το εμβαδόν της εκθετικής με $\lambda = 1$. Άρα $\Gamma(2) = 1$, $\Gamma(3) = 2 \cdot 1 = 2$, $\Gamma(4) = 3 \cdot 2 = 6$: $\Gamma(n) = (n-1)!$.

- **Ανάμεσα:** $\Gamma(0.5) = \sqrt{\pi} = 1.772454$, άρα $\Gamma(1.5) = 0.5 \cdot \Gamma(0.5) = 0.886227$.

Η Gamma στη γενική της μορφή

$$f(t) = \frac{\lambda^k t^{k-1} e^{-\lambda t}}{\Gamma(k)}, \qquad t \geq 0, \quad k > 0$$

- Ο αριθμητής είναι ο ίδιος. Ο παρονομαστής $\Gamma(k)$ είναι το εμβαδόν του αριθμητή (με $y = \lambda t$), ώστε το συνολικό εμβαδόν να είναι 1.
- Για ακέραιο k είναι $\Gamma(k) = (k-1)!$, και ξαναπαίρνουμε την Erlang. Δεν είναι άλλη κατανομή: είναι το όνομα της Gamma όταν το k είναι ακέραιο.
- Με $k = 2.5$ το «2.5 γεγονότα» δεν έχει νόημα, άρα χάνεται η ερμηνεία «άθροισμα k εκθετικών». Η καμπύλη όμως υπάρχει, και χρησιμεύει ως ευέλικτο σχήμα. Εμείς μένουμε σε ακέραια k.

Σύνοψη της Gamma

μηχανισμός	αναμονή για το k-οστό γεγονός (άθροισμα k ανεξάρτητων εκθετικών)
στα διακριτά	αρνητική διωνυμική (άθροισμα γεωμετρικών)
παράμετροι	k, λ
$f(t)$	$\lambda^k t^{k-1} e^{-\lambda t}/(k-1)!$ (ακέραιο k)
$F(t)$	$1 - \sum_{i<k} e^{-\lambda t}(\lambda t)^i/i!$ (ακέραιο k)
$\mathbb{E}[T]$	k/λ
$\mathrm{Var}(T)$	k/λ^2
γενικό $k > 0$	$f(t) = \lambda^k t^{k-1} e^{-\lambda t}/\Gamma(k)$
άλλη γραφή	Gamma(α, β) με $\alpha = k$, $\beta = 1/\lambda$

Για $k = 1$ ξαναγίνεται η εκθετική.

H Beta

Beta distribution

Το επόμενο μέγεθος: μια άγνωστη πιθανότητα

Ένας αισθητήρας δίνει σωστή μέτρηση με πιθανότητα X, που δεν την ξέρουμε. Παίρνουμε 5 μετρήσεις και οι 4 βγαίνουν σωστές. Άρα $X = 0.8$;

- Με 5 μόνο μετρήσεις, όχι. Θα μπορούσαν κάλλιστα να βγουν 5, που θα έδινε $X = 1$, ή 3, που θα έδινε $X = 0.6$. Λίγες δοκιμές δίνουν ακραία ποσοστά.
- Και ξέρουμε κάτι πριν καν μετρήσουμε: στους αισθητήρες που χρησιμοποιούμε το X κυμαίνεται γύρω στο 0.7, σπάνια κάτω από 0.4 ή πάνω από 0.95.
- Άρα το *ίδιο το* X είναι τυχαία μεταβλητή: κάθε αισθητήρας έχει τη δική του τιμή.

Τι μοντελοποιεί

Η πιθανότητα μια **άγνωστη πιθανότητα ή ποσοστό**, με τιμές στο $[0, 1]$, να πέσει σε ένα διάστημα.

Ποια είναι η τυχαία μεταβλητή εδώ

Η τυχαία μεταβλητή X είναι η **ίδια η άγνωστη πιθανότητα**. Γι΄ αυτό και ο οριζόντιος άξονας θα είναι πιθανότητα: πάνω του παρατάσσονται όλες οι τιμές που μπορεί να πάρει.

- Κάθε τιμή p που μπορεί να πάρει η X είναι μια **υποψήφια εξήγηση**: «μήπως ο αισθητήρας είναι 90% σωστός; Μήπως 50%;»
- Δεν μπορούμε να διαλέξουμε μία. Μπορούμε όμως να *βαθμολογήσουμε* την καθεμία: πόσο καλά εξηγεί αυτό που είδαμε.
- Η Beta είναι ακριβώς αυτές οι βαθμολογίες, ζωγραφισμένες σε καμπύλη. Ύψος στο p $=$ πόσο καλά αυτό το p εξηγεί τα δεδομένα.

Ποιο p εξηγεί καλύτερα αυτό που είδαμε

Με πιθανότητα p για σωστή, οι 4 σωστές και η 1 λάθος, ανεξάρτητες, έχουν πιθανότητα $p^4(1-p)$. Με αυτή βαθμολογούμε κάθε υποψήφιο p:

p	p^4	$1-p$	γινόμενο	από $100\,000$	τι το κόβει
0.90	0.6561	0.10	0.06561	$6\,561$	το λάθος που είδαμε
0.80	0.4096	0.20	0.08192	$8\,192$	**τίποτα: η καλύτερη**
0.50	0.0625	0.50	0.03125	$3\,125$	οι 4 σωστές
0.30	0.0081	0.70	0.00567	567	οι 4 σωστές

- Οι δύο παράγοντες **τραβούν αντίθετα**. Χωρίς το $(1-p)$ θα κέρδιζε το $p=1$.
- Η κορυφή πέφτει στο $4/5 = 0.8$, το ποσοστό που είδαμε. Γενικά, με $a-1$ σωστές και $b-1$ λάθος, το σχήμα είναι $p^{a-1}(1-p)^{b-1}$: εδώ $a=5$, $b=2$.
- Νέα μέτρηση, νέος εκθέτης: σωστή δίνει $a=6$, λάθος $b=3$.

Ορισμός

Το *σχήμα* το φτιάξαμε ήδη: $p^{a-1}(1-p)^{b-1}$, με $a-1$ σωστές και $b-1$ λάθος. Λείπει μόνο η σταθερά που κάνει το εμβαδόν 1, όπως ακριβώς και στη Gamma:

$$\int_0^1 p^{a-1}(1-p)^{b-1}\,dp = \frac{\Gamma(a)\,\Gamma(b)}{\Gamma(a+b)}.$$

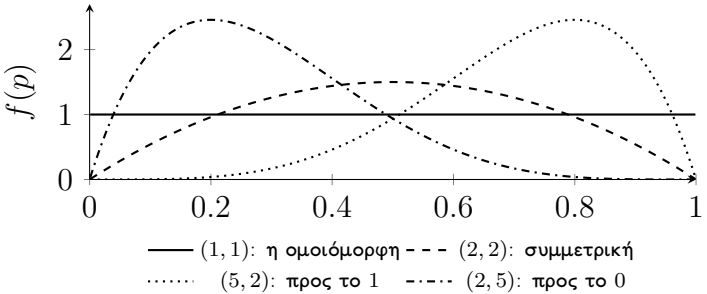
Διαιρώντας με αυτό ακριβώς το εμβαδόν, παίρνουμε πυκνότητα:

Η κατανομή Beta(a,b), με $a,b>0$

$$f(p) = \frac{\Gamma(a+b)}{\Gamma(a)\,\Gamma(b)}\,p^{a-1}(1-p)^{b-1}, \qquad 0 \le p \le 1$$

- Η ίδια Γ με πριν: $\Gamma(a) = \int_0^\infty e^{-y}y^{a-1}\,dy$, που για ακέραιο a δίνει $(a-1)!$.
- Η σταθερά δεν εξαρτάται από το p: το **σχήμα** το ορίζουν τα a,b, και η αθροιστική, για ακέραια a,b, είναι πολυώνυμο.

Τέσσερα ζεύγη (a, b), ένα σχήμα



- Η $(1, 1)$ είναι η ομοιόμορφη, ύψος 1 παντού. Η $(2, 2)$ συμμετρική με κορυφή 0.5, η $(5, 2)$ με κορυφή 0.8, και η $(2, 5)$ η κατοπτρική της.
- Και οι τέσσερις ζουν στο ίδιο διάστημα· αλλάζει μόνο πού μαζεύεται η μάζα. Η Beta είναι κατανομή **ποσοστών**.

Μέση τιμή και διασπορά

$$\mathbb{E}[X] = \frac{a}{a+b}, \qquad \mathrm{Var}(X) = \frac{ab}{(a+b)^2\,(a+b+1)}$$

$Beta(a,b)$	$\mathbb{E}[X]$	κορυφή	$\mathrm{Var}(X)$	τυπ. απόκλιση
$(1,1)$	0.5		0.083333	0.288675
$(2,2)$	0.5	0.5	0.05	0.223607
$(5,2)$	0.714286	0.8	0.025510	0.159719
$(2,5)$	0.285714	0.2	0.025510	0.159719

Η μέση τιμή είναι το κλάσμα του a στο σύνολο $a+b$: το a «ψηφίζει» για το 1 και το b για το 0. Στη Beta$(1,1)$ η πυκνότητα είναι επίπεδη, άρα κορυφή δεν ορίζεται και το κελί μένει κενό. Στη Beta$(5,2)$ η μέση τιμή 0.714286 είναι **αριστερά** της κορυφής 0.8, γιατί η ουρά προς τα μικρά p τραβάει τον μέσο όρο.

Πίσω στους αισθητήρες: η πυκνότητα και η F

Η Beta$(5, 2)$ των 5 μετρήσεων ταιριάζει και με το ιστορικό μας, «γύρω στο 0.7»: την παίρνουμε ως κατανομή του X. **Οι παράμετροι και η σταθερά**, με $\Gamma(n) = (n-1)!$:

$$a = \underbrace{4}_{\text{σωστές}} + 1 = 5, \qquad b = \underbrace{1}_{\text{λάθος}} + 1 = 2,$$

$$\frac{\Gamma(a+b)}{\Gamma(a)\,\Gamma(b)} = \frac{\Gamma(7)}{\Gamma(5)\,\Gamma(2)} = \frac{6!}{4!\cdot 1!} = \frac{720}{24\cdot 1} = 30.$$

Η πυκνότητα, με εκθέτες $a-1=4$ και $b-1=1$:

$$f(u) = 30\,u^{5-1}(1-u)^{2-1} = 30\,u^4(1-u) = 30\,u^4 - 30\,u^5.$$

Η F: με ακέραια a, b ολοκληρώνουμε πολυώνυμο,

$$F(p) = \int_0^p \left(30\,u^4 - 30\,u^5\right) du = 30\,\frac{p^5}{5} - 30\,\frac{p^6}{6} = 6p^5 - 5p^6.$$

Πίσω στους αισθητήρες, με αριθμούς

Με $a = 5$, $b = 2$ και $F(p) = 6p^5 - 5p^6$:

- **Μέση τιμή και διασπορά:**

$$\mathbb{E}[X] = \frac{a}{a+b} = \frac{5}{7} = 0.714286, \qquad \mathrm{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)} = \frac{5 \cdot 2}{7^2 \cdot 8} = \frac{10}{392},$$

  άρα τυπική απόκλιση $\sqrt{10/392} = 0.159719$.

- **Πάνω από** 90% **σωστές:**

$$\mathbb{P}(X > 0.9) = 1 - F(0.9) = 1 - \left(6 \cdot 0.9^5 - 5 \cdot 0.9^6\right) = 1 - 0.885735 = 0.114265.$$

- **Κάτω από τις μισές σωστές:** $\mathbb{P}(X < 0.5) = F(0.5) = 6 \cdot 0.5^5 - 5 \cdot 0.5^6 = 0.109375.$

- **Ανάμεσα:** $\mathbb{P}(0.6 < X < 0.9) = F(0.9) - F(0.6) = 0.885735 - 0.233280 = 0.652455.$

Σύνοψη της Beta

μηχανισμός	μέγεθος που είναι κλάσμα, στο $[0, 1]$
παράμετροι	$a > 0$, $b > 0$
$f(p)$	$\dfrac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\, p^{a-1}(1-p)^{b-1}$
$F(p)$	$\displaystyle\int_0^p f(u)\, du$
	πολυώνυμο για ακέραια a, b, αλλιώς αριθμητικά
$\mathbb{E}[X]$	$a/(a+b)$
$\mathrm{Var}(X)$	$ab/\big((a+b)^2(a+b+1)\big)$

Η κανονική

normal (Gaussian) distribution

Κανονική: η αντίσταση που δεν είναι ποτέ ακριβώς 100

Ανοίγουμε ένα σακουλάκι με αντιστάσεις των $100\,\Omega$ και τις μετράμε μία μία. Καμία δεν δίνει ακριβώς 100: βλέπουμε 97.8, 101.6, 99.1, 102.3, ...

Οι τιμές μαζεύονται γύρω από το 100, συμμετρικά, και όσο απομακρυνόμαστε τόσο σπανίζουν. Γιατί αυτό το σχήμα;

- Η απόκλιση δεν έχει *μία* αιτία αλλά πολλές: πάχος, θερμοκρασία, καθαρότητα, κοπή.
- Καθεμία αλλάζει λίγο την τιμή, ανεξάρτητα, και μετράμε το **άθροισμά** τους.
- Καμία δεν **κυριαρχεί**: η καθεμία δίνει μικρό μέρος της συνολικής διασποράς.

Τι μοντελοποιεί

Η πιθανότητα το **άθροισμα** πολλών ανεξάρτητων επιδράσεων, από τις οποίες καμία δεν κυριαρχεί, να πέσει σε ένα διάστημα.

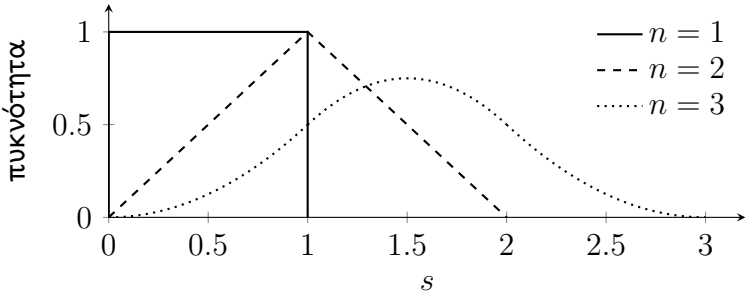
Το πείραμα: αθροίσματα ομοιόμορφων

Παίρνουμε n ανεξάρτητες ομοιόμορφες στο $(0,1)$ και τις προσθέτουμε, $S_n = X_1 + \cdots + X_n$. Κάθε X_i είναι μια μικρή ανεξάρτητη επίδραση, όπως αυτές που μετακινούν την τιμή μιας αντίστασης. Η ομοιόμορφη είναι **επίπεδη**, όσο πιο μακριά από «καμπάνα» γίνεται: αν εμφανιστεί καμπάνα, την έφερε η *πρόσθεση*.

- $n = 1$: η ίδια η ομοιόμορφη, ένα ορθογώνιο στο $[0,1]$ με ύψος 1.
- $n = 2$: τιμές στο $[0,2]$. Για να βγει 2 πρέπει *και οι δύο* να είναι κοντά στο 1, ένας τρόπος. Για να βγει 1 υπάρχουν πολλοί: $0.5 + 0.5$, $0.2 + 0.8$, $0.9 + 0.1$. Άρα η πυκνότητα αποκτά κορυφή στο κέντρο: τρίγωνο.

Ίδιο με δύο ζάρια: το 7 έρχεται πιο συχνά από το 12 επειδή **περισσότεροι συνδυασμοί** το δίνουν. Η πρόσθεση μαζεύει μάζα στη μέση.

Η καμπάνα εμφανίζεται



Ορθογώνιο, τρίγωνο, και στο $n = 3$ η καμπάνα φαίνεται ήδη. Κάθε ομοιόμορφη έχει $\mathbb{E}[X_i] = 1/2$ και $\mathrm{Var}(X_i) = 1/12$, και είναι ανεξάρτητες, άρα $\mathbb{E}[S_n] = n/2$ και $\mathrm{Var}(S_n) = n/12$. Το κέντρο πάει δεξιά και η καμπύλη απλώνεται, αλλά κάθε X_i δίνει μόνο το $1/n$ της διασποράς: όσο μικραίνει αυτό, το **σχήμα** πλησιάζει μία συγκεκριμένη καμπάνα.

Η πυκνότητα της κανονικής

Γιατί βγαίνει καμπάνα; Κοντά στο κέντρο καταλήγουν πολλοί συνδυασμοί, όπως το 7 στα δύο ζάρια: οι αποκλίσεις προς τα πάνω και προς τα κάτω αλληλοαναιρούνται. Μακριά από το κέντρο φτάνουμε μόνο αν σχεδόν όλες μετακινήσουν την τιμή προς την ίδια μεριά, κάτι σπάνιο, και κάθε βήμα πιο μακριά κόβει την πιθανότητα ανάλογα με την απόσταση. Γι' αυτό οι ουρές σβήνουν πολύ γρήγορα.

Αυτή η καμπάνα είναι η **κανονική**, με δύο παραμέτρους, το κέντρο μ και το πλάτος $\sigma > 0$:

Κανονική κατανομή

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

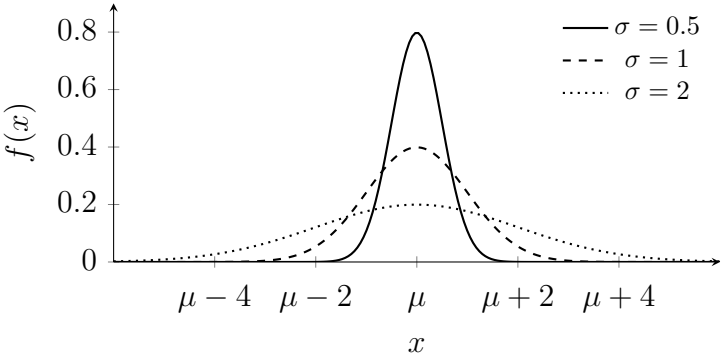
Το $1/(\sigma\sqrt{2\pi})$ κάνει το εμβαδόν 1. Γράφουμε $X \sim N(\mu, \sigma^2)$.

Τα κομμάτια του τύπου

Το σχήμα το δίνει ο εκθέτης, και διαβάζεται από μέσα προς τα έξω:

- Το $x - \mu$ είναι πόσο απέχει το x από το κέντρο.
- Με το **τετράγωνο** χάνεται το πρόσημο: οι δύο πλευρές του κέντρου μετράνε το ίδιο, και η καμπύλη είναι συμμετρική.
- Η διαίρεση με σ^2 μετράει την απόσταση **σε πλάτη**: με $z = (x - \mu)/\sigma$ ο εκθέτης γίνεται απλώς $-z^2/2$. Ένα σημείο σε απόσταση σ μετράει το ίδιο, όποιες κι αν είναι οι μονάδες.
- Το $\exp(-\ldots)$ μετατρέπει την απόσταση σε **ύψος**, ως κλάσμα της κορυφής: στο κέντρο $\exp(0) = 1$, και όσο απομακρυνόμαστε πέφτει προς το 0 χωρίς να το φτάνει.

Ίδιο κέντρο, τρία πλάτη



Όλες με κέντρο μ. Όσο μεγαλώνει το σ, η καμπάνα γίνεται φαρδύτερη και χαμηλότερη, ώστε το εμβαδόν να μένει 1.

Μέση τιμή και διασπορά

$$\mathbb{E}[X] = \mu, \qquad \mathrm{Var}(X) = \sigma^2$$

- Η καμπύλη είναι συμμετρική γύρω από το μ, άρα $\mathbb{E}[X] = \mu$.
- Η διασπορά, $\mathrm{Var}(X) = \int_{-\infty}^{\infty} (x-\mu)^2 f(x)\,dx = \sigma^2$, βγαίνει με ολοκλήρωση κατά μέρη.
- Οι δύο παράμετροι είναι ακριβώς η μέση τιμή και η διασπορά. Το άθροισμα των n ομοιόμορφων, με $\mathbb{E}[S_n] = n/2$ και $\mathrm{Var}(S_n) = n/12$, είναι λοιπόν περίπου $N(n/2,\, n/12)$.

Η τυποποιημένη κανονική

Η **τυποποίηση** αφαιρεί τη μέση τιμή και διαιρεί με την τυπική απόκλιση:

$$Z = \frac{X - \mathbb{E}[X]}{\sqrt{\mathrm{Var}(X)}},$$

και δίνει πάντα $\mathbb{E}[Z] = (\mathbb{E}[X] - \mathbb{E}[X])/\sqrt{\mathrm{Var}(X)} = 0$ και $\mathrm{Var}(Z) = \mathrm{Var}(X)/\mathrm{Var}(X) = 1$. Για την κανονική, $\mathbb{E}[X] = \mu$ και $\sqrt{\mathrm{Var}(X)} = \sigma$, άρα $Z = (X - \mu)/\sigma$. Με $x = \mu + \sigma z$ ο εκθέτης της f γίνεται $-(\sigma z)^2/(2\sigma^2) = -z^2/2$: αλλάζει μόνο ο άξονας, και το Z είναι πάλι κανονικό, με $\mu = 0$ και $\sigma = 1$. Αυτή είναι η **τυποποιημένη κανονική** $N(0, 1)$, που θα τη χρησιμοποιούμε συνεχώς:

Τυποποιημένη κανονική

$$\varphi(z) = \frac{1}{\sqrt{2\pi}}\, e^{-z^2/2}$$

Η Φ: τι είναι και τι ιδιότητες έχει

Η αθροιστική της τυποποιημένης κανονικής

$$\Phi(z) = \mathbb{P}(Z \leq z), \qquad Z \sim N(0,1)$$

δηλαδή το εμβαδόν κάτω από την καμπάνα, αριστερά του z.

- **Δεν έχει κλειστό τύπο.** Το ολοκλήρωμα της $e^{-z^2/2}$ δεν γράφεται με στοιχειώδεις συναρτήσεις, και γι' αυτό ακριβώς η Φ τυπώνεται σε πίνακες.
- **Αύξουσα**, από το 0 ως το 1, αφού είναι αθροιστική.
- Η καμπάνα είναι **συμμετρική** γύρω από το 0 (άρτια), άρα:

$$\Phi(0) = \tfrac{1}{2}, \qquad \Phi(-z) = 1 - \Phi(z).$$

Η μετάφραση της ερώτησης, και ένα παράδειγμα

$$\begin{aligned}\mathbb{P}(X \leq x) &= \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) \\ &= \mathbb{P}\left(Z \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right)\end{aligned}$$

Αφαιρέσαμε μ και διαιρέσαμε με σ και στις δύο πλευρές της ανισότητας: αριστερά μένει το Z, και επειδή το σ είναι θετικό, η φορά δεν αλλάζει. Ένας πίνακας, της Φ, αρκεί για κάθε κανονική.

Για τις αντιστάσεις, με $X \sim N(100, 2^2)$ σε Ω:

$$\mathbb{P}(X \leq 102) = \Phi\left(\frac{102-100}{2}\right) = \Phi(1),$$

και το $\Phi(1)$ το διαβάζουμε στον πίνακα.

Ο πίνακας Φ

z	$\Phi(z)$	z	$\Phi(z)$
0	0.500000	1.96	0.975002
0.5	0.691462	2	0.977250
1	0.841345	2.33	0.990097
1.28	0.899727	2.58	0.995060
1.645	0.950015	3	0.998650

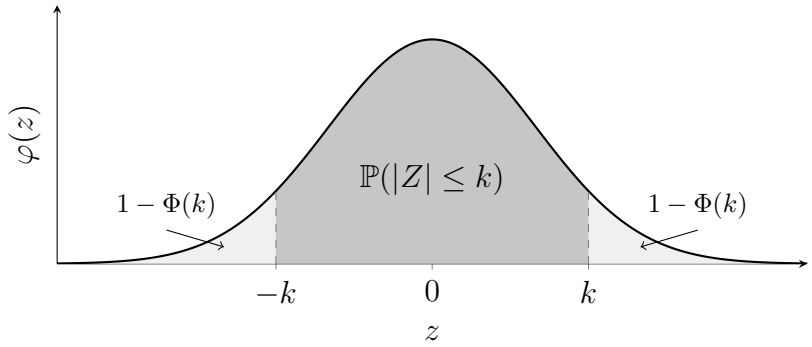
Στη γραμμή $z = 1$, $\Phi(1) = 0.841345$: το 84% είναι κάτω από τα $102\,\Omega$.

Αρνητικά z ο πίνακας δεν έχει. Τα παίρνουμε από τη συμμετρία $\Phi(-z) = 1 - \Phi(z)$: $\Phi(-1) = 1 - 0.841345 = 0.158655$.

Ανάποδα, από την πιθανότητα στο z: για 95% ανάμεσα στο $-z$ και το z μένει 2.5% σε κάθε ουρά, άρα $\Phi(z) = 0.975$ και $z = 1.96$.

Τι σημαίνει $|Z| \leq k$

Το $|Z| \leq k$ σημαίνει $-k \leq Z \leq k$: το Z πέφτει το πολύ k μακριά από το κέντρο 0, προς οποιαδήποτε μεριά. Η πιθανότητα είναι το εμβαδόν της μεσαίας λωρίδας. Με $<$ αντί για $\leq$ το εμβαδόν δεν αλλάζει: ένα σημείο έχει πιθανότητα 0.



Ο τύπος: όλο το εμβαδόν, μείον δύο ίσες ουρές

1. **Η λωρίδα**: ό,τι μαζεύτηκε ως το k, μείον ό,τι ως το $-k$:

$$\mathbb{P}(|Z| \leq k) = \mathbb{P}(-k \leq Z \leq k) = \Phi(k) - \Phi(-k).$$

2. **Συμμετρία γύρω από το** 0: η αριστερή ουρά ισούται με τη δεξιά:

$$\Phi(-k) = \underbrace{\mathbb{P}(Z \leq -k)}_{\text{αριστερή ουρά}} = \underbrace{\mathbb{P}(Z \geq k)}_{\text{δεξιά ουρά}} = 1 - \Phi(k).$$

3. **Αντικαθιστούμε**: βγαίνει όλο το εμβαδόν, 1, μείον δύο ουρές.

$$\mathbb{P}(|Z| \leq k) = \Phi(k) - \big(1 - \Phi(k)\big) = 1 - 2\big(1 - \Phi(k)\big)$$

$$\mathbb{P}(|Z| \leq k) = 2\Phi(k) - 1$$

Οι τρεις ζώνες: ο υπολογισμός

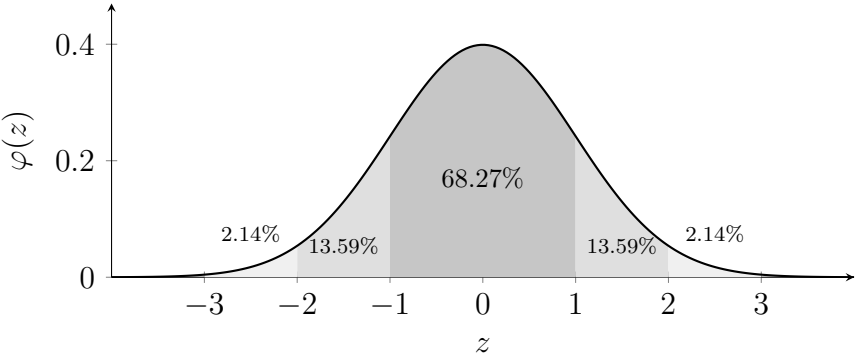
Πόση πιθανότητα πέφτει μέσα σε k τυπικές αποκλίσεις από το κέντρο; Με $Z = (X - \mu)/\sigma$, το $|X - \mu| \leq k\sigma$ είναι το ίδιο γεγονός με το $|Z| \leq k$, για κάθε κανονική:

$$\mathbb{P}(|X - \mu| \leq k\sigma) = 2\Phi(k) - 1.$$

Για $k = 1, 2, 3$, με τιμές από τον πίνακα:

$$\begin{aligned} k = 1: &\quad 2 \cdot 0.841345 - 1 = 0.682690 = 68.27\% \\ k = 2: &\quad 2 \cdot 0.977250 - 1 = 0.954500 = 95.45\% \\ k = 3: &\quad 2 \cdot 0.998650 - 1 = 0.997300 = 99.73\% \end{aligned}$$

Οι τρεις ζώνες σε ένα σχήμα



Οι ζώνες αθροίζονται σε όσα υπολογίσαμε: 68.27 στο κέντρο, $68.27 + 2(13.59) = 95.45$ ως τα $\pm 2\sigma$, $+\,2(2.14) = 99.73$ ως τα $\pm 3\sigma$.

Αθροίσματα κανονικών

Δύο ανεξάρτητες τάσεις σε σειρά, $X_1 \sim N(5, 0.15^2)$ και $X_2 \sim N(3, 0.20^2)$ σε V. Τι κατανομή έχει το άθροισμά τους;

Για ανεξάρτητες κανονικές X_1, X_2

$$X_1 + X_2 \sim N\big(\mu_1 + \mu_2,\ \sigma_1^2 + \sigma_2^2\big)$$

Οι μέσες τιμές προστίθενται πάντα, οι διασπορές μόνο για ανεξάρτητες. Ότι μένει κανονική το δεχόμαστε χωρίς απόδειξη, και δεν είναι αυτονόητο: δύο ομοιόμορφες δίνουν τρίγωνο.

Για τις δύο τάσεις μας: $X_1 + X_2 \sim N(5+3,\ 0.15^2 + 0.20^2) = N(8,\ 0.0625)$, άρα $\sigma = \sqrt{0.0625} = 0.25$. Προστίθενται οι **διασπορές**, όχι οι τυπικές αποκλίσεις: το $0.15 + 0.20 = 0.35$ είναι λάθος κατά 40%, όχι στρογγυλοποίηση.

Μια ερώτηση: το άθροισμα πολλών μικρών σφαλμάτων

Ένα πρόγραμμα αθροίζει 48 *αριθμούς που υπολογίστηκαν αριθμητικά, ο καθένας στρογγυλεμένος στον πλησιέστερο ακέραιο. Το σφάλμα στρογγυλοποίησης του καθενός είναι ομοιόμορφο στο* $[-0.5, 0.5]$ *και ανεξάρτητο από τα άλλα. Πόσο πιθανό είναι το συνολικό σφάλμα* S *να μείνει μέσα στο* ± 4*;*

Είναι άθροισμα 48 ανεξάρτητων όρων, και καθένας δίνει μόνο το $1/48$ της διασποράς: κανένας δεν κυριαρχεί, άρα το S είναι περίπου κανονικό, με

$$\mathbb{E}[S] = 48 \cdot \frac{a+b}{2} = 48 \cdot 0 = 0, \qquad \mathrm{Var}(S) = 48 \cdot \frac{(b-a)^2}{12} = 48 \cdot \frac{1}{12} = 4, \qquad \sigma = 2.$$

Το ± 4 είναι $\pm 2\sigma$, άρα $\mathbb{P}(|S| \le 4) = 2\Phi(2) - 1 = 0.954500$.

Σύνοψη της κανονικής

μηχανισμός	άθροισμα πολλών ανεξάρτητων όρων, χωρίς κυρίαρχο (όποια κι αν είναι η κατανομή τους)
παράμετροι	μ, $\sigma > 0$
$f(x)$	$\frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)}$
$F(x)$	$\Phi\big(\frac{x-\mu}{\sigma}\big)$, χωρίς στοιχειώδη μορφή
$\mathbb{E}[X]$	μ
$\mathrm{Var}(X)$	σ^2
τυποποίηση	$Z = (X-\mu)/\sigma \sim N(0,1)$: ένας πίνακας για όλες

Μέσα σε $\pm\sigma$, $\pm 2\sigma$, $\pm 3\sigma$ από τη μέση τιμή πέφτει το 68.27%, το 95.45% και το 99.73%. Για το 95% χρειάζεται $\pm 1.96\,\sigma$, όχι $\pm 2\sigma$.

Η λογαριθμοκανονική

lognormal distribution

Λογαριθμοκανονική: όταν οι αιτίες πολλαπλασιάζονται

Βάζετε 1000 ευρώ σε έναν λογαριασμό. Κάθε χρόνο το ποσό αλλάζει κατά ένα *τυχαίο ποσοστό*: άλλοτε $+12\%$, άλλοτε -8%. Μετά από 10 χρόνια, τι κατανομή έχει το ποσό;

- Η αλλαγή είναι **ποσοστό**, άρα κάθε χρονιά *πολλαπλασιάζει* ό,τι έχει μαζευτεί.
- Μένει θετικό, με πολλά μικρά ποσά και λίγα πολύ μεγάλα: η κανονική δεν κάνει.
- **Προσοχή**: δεν ρωτάμε πώς εξελίσσεται το ποσό, αλλά πού *καταλήγει*: χίλιοι ίδιοι λογαριασμοί δίνουν χίλια διαφορετικά ποσά, και η κατανομή είναι αυτό το άπλωμα.

Τι μοντελοποιεί

Η πιθανότητα το **γινόμενο** πολλών ανεξάρτητων παραγόντων, από τους οποίους κανένας δεν κυριαρχεί, να πέσει σε ένα διάστημα.

Το μοντέλο

- Το ποσό μετά από n χρόνια γράφεται ως γινόμενο:

$$X = X_0 \cdot A_1 \cdot A_2 \cdots A_n,$$

με X_0 την αρχική τιμή και A_i τους τυχαίους παράγοντες.

- Η κανονική δεν βοηθά, γιατί ξέρουμε τι κάνει σε **αθροίσματα**, όχι σε γινόμενα.

Και το γινόμενο φέρνει μόνο του την ασυμμετρία

Μια κακή σειρά από παράγοντες μικρότερους του 1 *συρρικνώνει* το ποσό προς το μηδέν, αλλά ποτέ κάτω από αυτό: κάθε πολλαπλασιασμός αφαιρεί ένα *ποσοστό* απ' ό,τι έχει μείνει. Μια καλή σειρά όμως ανατοκίζεται, και προς τα πάνω δεν υπάρχει ταβάνι. Στριμωγμένο αριστερά, ελεύθερο δεξιά.

Η κίνηση που δουλεύει, και ο ορισμός

Ο λογάριθμος μετατρέπει γινόμενα σε αθροίσματα:

$$\ln X = \ln X_0 + \ln A_1 + \ln A_2 + \cdots + \ln A_n.$$

Το δεξί μέλος είναι άθροισμα πολλών ανεξάρτητων όρων, και αν κανένας δεν κυριαρχεί, πλησιάζει την κανονική. Άρα κανονικός είναι, κατά προσέγγιση, ο *λογάριθμος* της X, όχι η ίδια.

Λογαριθμοκανονική κατανομή

Η X ακολουθεί λογαριθμοκανονική κατανομή αν η $Y = \ln X$ ακολουθεί την κανονική $N(\mu, \sigma^2)$.

Προσοχή: τα μ και σ είναι του **λογαρίθμου**, όχι της X.

Η αθροιστική, αφού ο λογάριθμος είναι γνησίως αύξων:

$$F_X(x) = \mathbb{P}(X \le x) = \mathbb{P}(\ln X \le \ln x) = \mathbb{P}(Y \le \ln x) = F_Y(\ln x) = \Phi\big((\ln x - \mu)/\sigma\big).$$

Η πυκνότητα: παραγωγίζουμε την F_X

1. **Κανόνας της αλυσίδας** στην $F_Y(\ln x)$: εξωτερική η F_Y, εσωτερική το $\ln x$.

$$f_X(x) = \frac{d}{dx}F_X(x) = \frac{d}{dx}F_Y(\ln x) = \underbrace{F_Y'(\ln x)}_{f_Y(\ln x)} \cdot \underbrace{\frac{d}{dx}\ln x}_{1/x} = f_Y(\ln x) \cdot \frac{1}{x}.$$

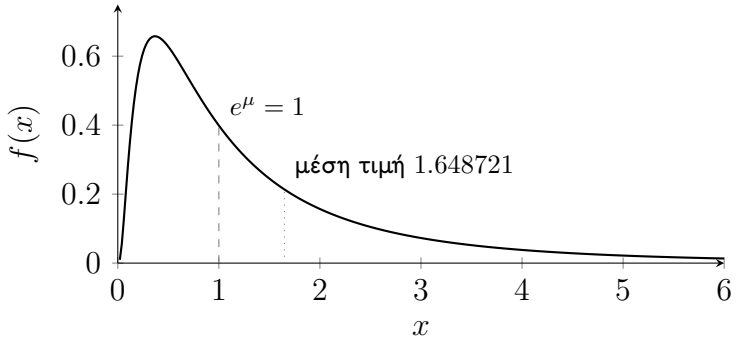
2. **Η f_Y είναι η πυκνότητα της** $N(\mu, \sigma^2)$. Βάζουμε $\ln x$ στη θέση του y:

$$f_Y(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right) \implies f_Y(\ln x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right).$$

3. **Πολλαπλασιάζουμε με** $1/x$:

$$f_X(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \qquad x > 0$$

Η καμπύλη, με $\mu = 0$ και $\sigma = 1$



Η μέση τιμή δεν είναι e^{μ}

Το μ είναι η μέση τιμή της $Y = \ln X$, και $X = e^{Y}$. Η μέση τιμή δεν μπαίνει μέσα στο e, γιατί γενικά $\mathbb{E}[g(Y)] \neq g(\mathbb{E}[Y])$:

$$\mathbb{E}[X] = \mathbb{E}\left[e^{Y}\right] \neq e^{\mathbb{E}[Y]} = e^{\mu}.$$

Η e^{y} καμπυλώνει προς τα πάνω, οπότε οι μεγάλες τιμές της Y τραβούν τη μέση τιμή **ψηλότερα** από το e^{μ}. Οι σωστοί τύποι:

$$\mathbb{E}[X] = e^{\mu+\sigma^2/2}, \qquad \mathrm{Var}(X) = \left(e^{\sigma^2} - 1\right) e^{2\mu+\sigma^2}$$

Βγαίνουν συμπληρώνοντας το τετράγωνο στον εκθέτη. Με $\mu = 0$ και $\sigma = 1$, το e^{μ} είναι 1, αλλά $\mathbb{E}[X] = 1.648721$ και $\sigma_X = 2.161197$.

Σύνοψη της λογαριθμοκανονικής

μηχανισμός	**γινόμενο** πολλών παραγόντων, χωρίς κυρίαρχο
ορισμός	$\ln X \sim N(\mu, \sigma^2)$
παράμετροι	μ, σ (της $\ln X$, όχι της X)
$f(x)$	$\frac{1}{x\sigma\sqrt{2\pi}} e^{-(\ln x - \mu)^2/(2\sigma^2)}$
$F(x)$	$\Phi\left(\frac{\ln x - \mu}{\sigma}\right)$
$\mathbb{E}[X]$	$e^{\mu+\sigma^2/2}$
$\mathrm{Var}(X)$	$(e^{\sigma^2} - 1)e^{2\mu+\sigma^2}$

Η μέση τιμή βγαίνει πάνω από το e^{μ}, γιατί την τραβούν ψηλά λίγες πολύ μεγάλες τιμές: οι περισσότερες μένουν κάτω από αυτήν.

Ο ρυθμός αστοχίας και η Weibull

hazard rate, Weibull distribution

Το ερώτημα που έμεινε ανοιχτό

- Είπαμε ότι η εκθετική είναι λάθος όταν υπάρχει φθορά.
- Αλλά δεν είπαμε τι σημαίνει «φθορά» με αριθμούς.
- Χρειαζόμαστε μια ποσότητα που να το μετράει.

Δεδομένου ότι το εξάρτημα δουλεύει τώρα, πόσο επικίνδυνη είναι η *επόμενη* ώρα;

Γράφουμε T τον **χρόνο ζωής** ενός εξαρτήματος, δηλαδή πόσο αντέχει ώσπου να αστοχήσει. Είναι τυχαία μεταβλητή, γιατί δύο ίδια εξαρτήματα δεν αστοχούν την ίδια στιγμή, και έχει τη δική της πυκνότητα f και αθροιστική F.

Πόσο επικίνδυνη είναι η επόμενη χρονιά

Παρακολουθούμε 1000 καινούριους πυκνωτές σε τροφοδοτικά.

	ζωντανοί στην αρχή	σκάνε στη χρονιά	h = σκάνε / ζωντανοί
Έτος 1	1000	10	$10/1000 = 0.01 = 1\%$
Έτος 10	50	10	$10/50 = 0.20 = 20\%$

Οι 10 που σκάνε είναι *μέσα* στους ζωντανούς: $1000 \to 990$ το έτος 1, $50 \to 40$ το έτος 10.

- Ο **αριθμητής είναι ίδιος**, 10 και τις δύο χρονιές: κοιτώντας μόνο αυτόν θα λέγαμε «ο κίνδυνος δεν άλλαξε».
- Στο δέκατο έτος όμως έχουν *μείνει* μόνο 50, και σκάει ο ένας στους πέντε: ο κίνδυνος για *τον δικό σας* πυκνωτή εικοσαπλασιάστηκε.

Το σχέδιο: το ίδιο κλάσμα σε κάθε στιγμή t

Ο πίνακας μέτρησε τον κίνδυνο: όσα αστοχούν διά όσα ζουν ακόμη. Τον θέλουμε για κάθε στιγμή t. Η μονάδα χρόνου είναι επιλογή μας: εδώ η ώρα, γιατί τα εξαρτήματα ζουν χιλιάδες ώρες.

$$h(t) = \frac{\text{αστοχούν ανά ώρα}}{\text{ζουν ακόμη}}.$$

Πάνω και κάτω όμως είναι **πλήθη**, που αλλάζουν με το πόσα εξαρτήματα ξεκίνησαν. Το μοντέλο για τον χρόνο ζωής T δίνει τις F και f, που δεν εξαρτώνται από αυτό. Γράφουμε λοιπόν το κλάσμα με αυτές:

- **Κάτω:** το «ζουν ακόμη», με την F.
- **Πάνω:** το «αστοχούν ανά ώρα», με την f.
- **Μαζί:** το κλάσμα, χωρίς πλήθη.

Κάτω στο κλάσμα: ζουν ακόμη

Ξεκινούν N **αρχικά** εξαρτήματα, στον πίνακα $N = 1000$. Η $F(t) = \mathbb{P}(T \leq t)$ είναι η **πιθανότητα** ένα εξάρτημα να έχει **ήδη αστοχήσει** ως τη στιγμή t. Σε πολλά εξαρτήματα είναι το **ποσοστό** που έχει αστοχήσει. Το ποσοστό που ζει είναι το υπόλοιπο, η **συνάρτηση επιβίωσης**:

$$S(t) = 1 - F(t) = \mathbb{P}(T > t).$$

Καινούριο όνομα, παλιά ποσότητα: η ουρά που είχαμε στην εκθετική. Το πλήθος είναι N επί το ποσοστό:

$$\text{ζουν ακόμη} = N \cdot S(t).$$

Στο δέκατο έτος: $S = 50/1000 = 0.05$, και $1000 \times 0.05 = 50$.

Μήπως μετράμε δύο φορές το $T = t$;

Η F έχει $\leq$ και η S έχει $>$, αλλά ο χρόνος είναι **συνεχής**: $\mathbb{P}(T = t) = 0$.

Πάνω στο κλάσμα: αστοχούν ανά ώρα

Η F δίνει το ποσοστό *ως* το t. Εδώ θέλουμε το ποσοστό *γύρω στο* t, και γι' αυτό χρειάζεται η f. Είναι **πυκνότητα**, όχι ποσοστό: το ποσοστό είναι το εμβαδόν της.

1. **Το ποσοστό σε μια λεπτή λωρίδα**, πλάτους dt, είναι το εμβαδόν της:

$$\mathbb{P}(t < T \leq t + dt) = f(t)\,dt.$$

2. **Το πλήθος** είναι N επί το ποσοστό:

$$\text{αστοχούν στη λωρίδα} = N \cdot f(t)\,dt.$$

3. **Ανά ώρα**: διαιρούμε με το πλάτος dt:

$$\text{αστοχούν ανά ώρα} = N \cdot f(t).$$

Στο δέκατο έτος: $10 \approx 1000 \cdot f$, άρα $f \approx 10/1000 = 0.01$ ανά χρονιά. Περίπου, γιατί η χρονιά είναι φαρδιά λωρίδα.

Ο ορισμός

Βάζουμε τα δύο στο κλάσμα. Το N είναι πάνω και κάτω, και απλοποιείται:

$$h(t) = \frac{\text{αστοχούν ανά ώρα}}{\text{ζουν ακόμη}} = \frac{N \cdot f(t)}{N \cdot S(t)} = \frac{f(t)}{S(t)}.$$

Η f είναι η παράγωγος της F, και $F = 1 - S$, άρα $f = F' = (1 - S)' = -S'$:

Ρυθμός αστοχίας

$$h(t) = \frac{f(t)}{S(t)} = \frac{f(t)}{1 - F(t)} = -\frac{S'(t)}{S(t)}$$

Στο δέκατο έτος: $h \approx 0.01/0.05 = 0.20$, το 20% του πίνακα.

Είναι **ρυθμός**, όχι πιθανότητα, όπως το λ, και ισχύει για *οποιαδήποτε* κατανομή χρόνου ζωής: άλλη f, άλλο h.

Αν οι πυκνωτές ήταν εκθετικοί

Με $f(t) = \lambda e^{-\lambda t}$ και $S(t) = e^{-\lambda t}$, το $e^{-\lambda t}$ είναι πάνω *και* κάτω στο $h = f/S$. Και αφού $\mathbb{E}[T] = 1/\lambda$, το λ γράφεται με τη μέση τιμή:

$$h(t) = \frac{\lambda e^{-\lambda t}}{e^{-\lambda t}} = \lambda = \frac{1}{\mathbb{E}[T]}, \qquad S(t) = e^{-\lambda t} = e^{-t/\mathbb{E}[T]}.$$

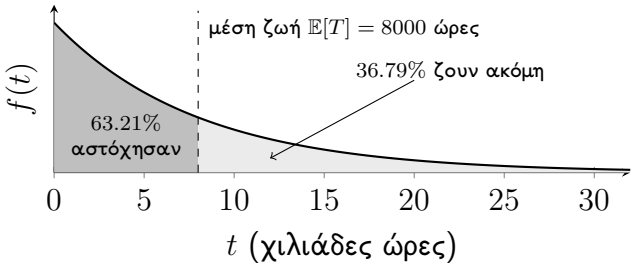
- Ο ρυθμός **δεν εξαρτάται από το** t. Το $\mathbb{E}[T]$ είναι η **μέση ζωή**: με MTBF (Mean Time Between Failures) 8000 ώρες, $\lambda = 1/8000 = 0.000125$ ανά ώρα.
- Ο χρόνος μετριέται σε μέσες ζωές, $t/8000$. Στις 8000 ώρες $S = e^{-1}$, άρα έχει αστοχήσει το 63.21%, όχι το μισό.
- Οι πυκνωτές όμως έδωσαν 1% και μετά 20%, άρα *δεν* είναι εκθετικοί.

Σταθερός ρυθμός αστοχίας και αμνησία είναι η ίδια πρόταση.

Γιατί αστοχούν περισσότερα από τα μισά;

Στην εκθετική, στο $t = \mathbb{E}[T]$ ο εκθέτης γίνεται -1 για κάθε μέση ζωή:

$$F(\mathbb{E}[T]) = 1 - e^{-\mathbb{E}[T]/\mathbb{E}[T]} = 1 - e^{-1} = 0.632121.$$



Η μέση τιμή δεν χωρίζει τα εξαρτήματα στα δύο: λίγα πολύ μακρόβια τραβούν τη μέση τιμή δεξιά. Ζωές 2000, 3000 και $19\,000$ ώρες έχουν μέση τιμή 8000, και δύο από τις τρεις τελειώνουν πριν από αυτήν.

Τι δείχνει η εμπειρία

- **Πρώτη περίοδος**: κακές κολλήσεις και ελαττωματικά υλικά αστοχούν γρήγορα. Ο ρυθμός *πέφτει*.
- **Δεύτερη περίοδος**: μένουν τα υγιή. Ο ρυθμός είναι σταθερός και μικρός.
- **Τρίτη περίοδος**: ηλεκτρομετανάστευση, ξήρανση πυκνωτών, κόπωση. Ο ρυθμός *ανεβαίνει*.

Είναι οι *ίδιοι* πυκνωτές, σε τρεις ηλικίες: μια παρτίδα περνάει και από τις τρεις περιόδους καθώς παλιώνει.

Τι ζητάμε

Ένα πρότυπο με **μία** παράμετρο που να ρυθμίζει αν το h πέφτει, μένει σταθερό ή ανεβαίνει, με την εκθετική ως ειδική περίπτωση. Καλύπτει *μία* περίοδο τη φορά.

Διαλέγουμε τον *ρυθμό*, και η κατανομή ακολουθεί

Εδώ το αντίστροφο: διαλέγουμε το h που **θέλουμε**, και βρίσκουμε την κατανομή.

- **Ξεκινάμε από την εκθετική**: ρυθμός 1 διά τη μέση ζωή. Τη μέση ζωή, σε ώρες, τη λέμε η: ρυθμός $1/\eta$, και ο χρόνος μετρημένος σε μέσες ζωές είναι t/η.
- Για να μπορεί ο ρυθμός να πέφτει ή να ανεβαίνει, τον πολλαπλασιάζουμε με μια **δύναμη** του t/η: ο εκθέτης αποφασίζει αν ο ρυθμός ανεβαίνει ή πέφτει.

Ο ρυθμός αστοχίας της Weibull

$$h(t) = \underbrace{k}_{\substack{\text{ώστε στο } \eta \text{ να έχει} \\ \text{αστοχήσει το } 63.21\%, \\ \text{για κάθε } k}} \cdot \underbrace{\frac{1}{\eta}}_{\substack{\text{ο ρυθμός της} \\ \text{εκθετικής}}} \cdot \underbrace{\left(\frac{t}{\eta}\right)^{k-1}}_{\substack{\text{δύναμη του χρόνου} \\ \text{μετρημένου σε } \eta}}$$

Με $k = 1$ μένει σταθερό $h = 1/\eta$: η εκθετική, με μέση ζωή η.

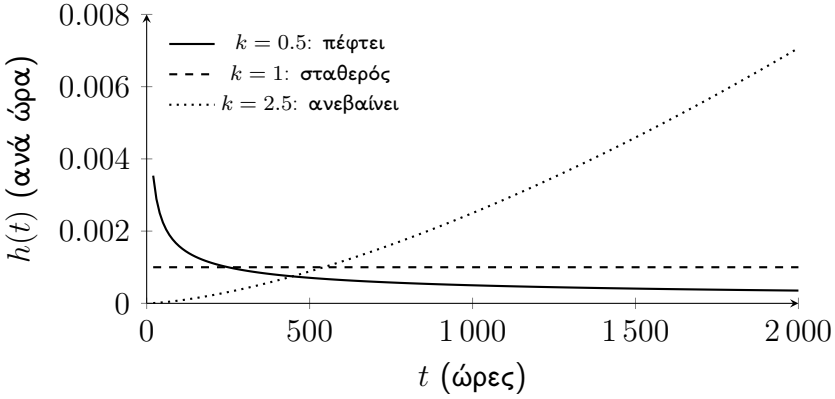
Το k είναι ο διακόπτης της γήρανσης

Ο εκθέτης $k-1$ στο $h(t) = \frac{k}{\eta}(t/\eta)^{k-1}$ αποφασίζει τα πάντα:

k	$h(t)$	μηχανισμός	παράδειγμα
< 1	**πέφτει**	βρεφική θνησιμότητα	κακές κολλήσεις, ελαττώματα
$= 1$	**σταθερός**	τυχαία εξωτερικά συμβάντα	υπέρταση, ακτινοβολία
> 1	**ανεβαίνει**	φθορά	ξήρανση πυκνωτών, κόπωση

- Με $k < 1$ ο εκθέτης είναι αρνητικός: ό,τι επιβιώνει τις πρώτες ώρες γίνεται *ασφαλέστερο*.
- Με $k = 1$ ο εκθέτης μηδενίζεται και μένει $h = 1/\eta$: είναι **ακριβώς η εκθετική** που μελετήσαμε, χωρίς μνήμη.
- Με $k > 1$ κάθε επιπλέον ώρα λειτουργίας κάνει την επόμενη πιο επικίνδυνη.

Τα τρία σχήματα, σε ένα σχήμα



Ίδιο $\eta = 1000$ και στις τρεις. Αλλάζει η *φορά*, και την ορίζει το k.

Από τον ρυθμό πίσω στην επιβίωση

1. **Ο ορισμός**, με $f = F' = (1-S)' = -S'$:

$$h(t) = \frac{f(t)}{S(t)} = -\frac{S'(t)}{S(t)} \overset{\text{αλυσίδα}}{=} -\frac{d}{dt}\ln S(t).$$

2. **Ολοκληρώνουμε το 1 από** 0 **ως** t, με $S(0) = \mathbb{P}(T > 0) = 1$:

$$\ln S(t) - \underbrace{\ln S(0)}_{\ln 1 = 0} = \int_0^t \frac{d}{du}\ln S(u)\,du = -\int_0^t h(u)\,du.$$

3. **Βάζουμε το** h **της Weibull**, με $w = u/\eta$: $du = \eta\,dw$, **και το όριο** t **γίνεται** t/η:

$$\int_0^t h(u)\,du = \int_0^t \frac{k}{\eta}\Big(\frac{u}{\eta}\Big)^{k-1} du = \int_0^{t/\eta} \frac{k}{\cancel{\eta}}\, w^{k-1}\,\cancel{\eta}\,dw = \cancel{k}\Big[\frac{w^k}{\cancel{k}}\Big]_0^{t/\eta} = \Big(\frac{t}{\eta}\Big)^k.$$

4. **Υψώνουμε στο** e: $\ln S(t) = -(t/\eta)^k \Rightarrow S(t) = e^{-(t/\eta)^k}$.

Η Weibull

Η S βγήκε στο βήμα 4, και η πυκνότητα είναι $f = h \cdot S$, αφού $h = f/S$:

Κατανομή Weibull

$$f(t) = \frac{k}{\eta}\left(\frac{t}{\eta}\right)^{k-1} e^{-(t/\eta)^k}, \qquad S(t) = \mathbb{P}(T > t) = e^{-(t/\eta)^k}, \qquad t \geq 0$$

Το η είναι κλίμακα, σε ώρες, και το k σχήμα, καθαρός αριθμός. Για $k = 1$ ο εκθέτης γίνεται $-t/\eta$, δηλαδή η εκθετική με μέση ζωή η, όπως το $e^{-t/8000}$. Η αθροιστική είναι το συμπλήρωμα, $F(t) = 1 - S(t)$.

Τι μοντελοποιεί

Η πιθανότητα ένας χρόνος ζωής με **μεταβαλλόμενο ρυθμό αστοχίας** να πέσει σε ένα διάστημα.

Τι σημαίνει το η, και τι *δεν* σημαίνει

Γράφουμε $T \sim Weibull(\eta, k)$: χρειάζονται **δύο** αριθμοί, η κλίμακα η και το σχήμα k.

- Βάζοντας $t = \eta$ στην S, ο εκθέτης γίνεται -1 για **κάθε** k: $S(\eta) = e^{-1} = 0.367879$. Δηλαδή στο $t = \eta$ έχει αστοχήσει πάντα το 63.21%.
- Είναι το ποσοστό που είδαμε στη μέση ζωή της εκθετικής: το η παίζει τον ρόλο της. Με $k = 1$ είναι η μέση ζωή, $\eta = 1/\lambda$. Με $k \neq 1$ η μέση ζωή μετακινείται, ενώ το 63.21% μένει στο η.

Προσοχή: το η **δεν** είναι ρυθμός

Το η είναι **χρόνος**, σε ώρες, γι' αυτό παίρνει άλλο γράμμα από το λ. Ρυθμός είναι το $h(t)$, ανά ώρα. Μόνο όταν $k = 1$ ο ρυθμός γίνεται σταθερός, $1/\eta$, και είναι το λ της εκθετικής: $\eta = 1000$ ώρες σημαίνει $\lambda = 0.001$ ανά ώρα.

Μέση τιμή και διασπορά της Weibull

$$\mathbb{E}[T] = \eta\,\Gamma\!\left(1+\tfrac{1}{k}\right), \qquad \mathrm{Var}(T) = \eta^2\left[\Gamma\!\left(1+\tfrac{2}{k}\right) - \Gamma\!\left(1+\tfrac{1}{k}\right)^2\right]$$

Η ίδια Γ με πριν. Για $k=1$ δίνει $\Gamma(2)=1$ και $\Gamma(3)=2$ $\Rightarrow$ $\mathbb{E}[T]=\eta$ και $\mathrm{Var}(T)=\eta^2$: ξαναβρίσκουμε την εκθετική.

Με $\eta = 1000$ ώρες, και τα τρία k του σχήματος:

k	$\mathbb{E}[T]$ (ώρες)	σ_T (ώρες)	$S(\eta)$
0.5	2000.00	4472.14	0.367879
1.0	1000.00	1000.00	0.367879
2.5	887.26	379.67	0.367879

Ίδιο η, ίδιο 63.21% στο $t=\eta$, τελείως διαφορετική ζωή: το k αλλάζει και τη μέση τιμή και, δραματικά, τη διασπορά.

Ένα παράδειγμα με νούμερα

Ένας πυκνωτής έχει $T \sim Weibull(\eta = 1000 \text{ ώρες},\ k = 2.5)$. Ποια η πιθανότητα να δουλεύει ακόμη στις 500 ώρες;

Ο τύπος. «Δουλεύει ακόμη στις 500» σημαίνει $T > 500$:

$$S(t) = \mathbb{P}(T > t) = \exp\left[-\left(\frac{t}{\eta}\right)^k\right].$$

Η αντικατάσταση, με $t = 500$, $\eta = 1000$, $k = 2.5$:

$$\frac{t}{\eta} = \frac{500}{1000} = 0.5, \qquad 0.5^{2.5} = 0.5^2 \cdot \sqrt{0.5} = 0.25 \times 0.707107 = 0.176777.$$

Η πράξη.

$$S(500) = e^{-0.176777} = 0.837967.$$

Ζει το 83.80%, και έχει αστοχήσει το 16.20%.

Σύνοψη της Weibull

μηχανισμός	**μεταβλητός** ρυθμός αστοχίας
παράμετροι	η (κλίμακα), k (σχήμα)
$f(t)$	$\frac{k}{\eta}(t/\eta)^{k-1}e^{-(t/\eta)^k}$
$F(t)$	$1-e^{-(t/\eta)^k}$ (κλειστός τύπος)
$\mathbb{E}[T]$	$\eta\,\Gamma(1+1/k)$
$\mathrm{Var}(T)$	$\eta^2[\Gamma(1+2/k)-\Gamma(1+1/k)^2]$
ρυθμός αστοχίας	$h(t)=f(t)/S(t)=\frac{k}{\eta}(t/\eta)^{k-1}$
άλλη γραφή	$\mathsf{WEI}(a,\beta)$ με $a=k$, $\beta=\eta$

Με $k<1$ ο ρυθμός αστοχίας πέφτει (βρεφική θνησιμότητα), με $k=1$ μένει σταθερός και παίρνουμε την εκθετική, με $k>1$ ανεβαίνει (φθορά).

Αξιοπιστία συστημάτων

system reliability

Σε σειρά: αρκεί ένα να χαλάσει

Την επιβίωση $S_i(t) = \mathbb{P}(T_i > t)$ του εξαρτήματος i σε έναν δεδομένο χρόνο t (π.χ. ένα έτος) τη λέμε **αξιοπιστία** R_i. Το σύστημα λειτουργεί μόνο αν λειτουργούν **όλα**. Με ανεξαρτησία, οι πιθανότητες πολλαπλασιάζονται:

$$R_{\text{σειρά}} = \mathbb{P}(\text{λειτουργούν όλα}) = R_1 \cdot R_2 \cdots R_n$$

πλήθος εξαρτημάτων (το καθένα 0.99)	αξιοπιστία συστήματος
1	0.99
10	0.904382
50	0.605006
100	0.366032

Κάθε εξάρτημα είναι εξαιρετικό, 99%, αλλά εκατό σε σειρά δίνουν μόλις 0.366032. **Όσο περισσότερα, τόσο χειρότερα.**

Παράλληλα: αρκεί ένα να αντέξει

Το σύστημα αστοχεί μόνο αν αστοχήσουν **όλα**. Πολλαπλασιάζουμε τώρα τις πιθανότητες *αστοχίας*:

$$R_{\text{παράλληλα}} = 1 - \underbrace{\underbrace{(1-R_1)}_{\mathbb{P}(\text{αστοχεί το } 1)} \quad \underbrace{(1-R_2)}_{\mathbb{P}(\text{αστοχεί το } 2)} \quad \cdots \quad \underbrace{(1-R_n)}_{\mathbb{P}(\text{αστοχεί το } n)}}_{\mathbb{P}(\text{αστοχούν όλα})}$$

πλήθος εξαρτημάτων (το καθένα 0.90)	1	2	3	4
αξιοπιστία συστήματος	0.9	0.99	0.999	0.9999

Ένα μέτριο εξάρτημα, 90%. Τέσσερα σε εφεδρεία δίνουν 99.99%. **Όσο περισσότερα, τόσο καλύτερα.**

Ένα πραγματικό παράδειγμα: οκτώ δίσκοι, δύο τρόποι

Οκτώ ίδιοι δίσκοι, ο καθένας επιβιώνει έναν χρόνο με πιθανότητα 0.98, και αλλάζει μόνο η συνδεσμολογία:

RAID 0: οι οκτώ σε σειρά

Κανένα αντίγραφο: ένας χαμένος δίσκος χάνει τα πάντα.

$$R = 0.98^8 = 0.850763$$

Χωρητικότητα 8 δίσκοι, απώλεια 14.92%.

RAID 10: κατοπτρισμένα ζευγάρια

Κάθε ζευγάρι αντέχει έναν χαμένο δίσκο: $1 - 0.02^2 = 0.9996$. Τα τέσσερα ζευγάρια είναι σε σειρά:

$$R = 0.9996^4 = 0.998401$$

Χωρητικότητα 4 δίσκοι, απώλεια 0.16%.

Με τη μισή χωρητικότητα, η απώλεια γίνεται 93 φορές μικρότερη.

Πώς διαλέγουμε πρότυπο

Ο πίνακας της ημέρας

μηχανισμός	κατανομή	$\mathbb{E}[X]$
καμία προτίμηση σε διάστημα	ομοιόμορφη	$(a+b)/2$
αναμονή σε διαδικασία Poisson	εκθετική	$1/\lambda$
αναμονή για το k-οστό γεγονός	Gamma	k/λ
μέγεθος που είναι κλάσμα, στο $[0,1]$	Beta	$a/(a+b)$
άθροισμα πολλών όρων, χωρίς κυρίαρχο	κανονική	μ
γινόμενο πολλών παραγόντων, χωρίς κυρίαρχο	λογαριθμοκανονική	$e^{\mu+\sigma^2/2}$
μεταβλητός ρυθμός αστοχίας	Weibull	$\eta\Gamma(1+1/k)$

Η αριστερή στήλη είναι η ερώτηση, η μεσαία η απάντηση, ποτέ το αντίστροφο. Κάθε γραμμή την παραγάγαμε από τον μηχανισμό της, εκτός από την κανονική, που τη βρήκαμε πειραματικά.

Τέσσερις ερωτήσεις πριν διαλέξετε

1. Η ποσότητα είναι φραγμένη ή όχι; Η ομοιόμορφη και η Beta είναι, η κανονική δεν είναι.
2. Μπορεί να είναι αρνητική; Αν όχι, η κανονική είναι επικίνδυνη.
3. Οι αιτίες προστίθενται ή πολλαπλασιάζονται; Αν προστίθενται, κανονική· αν πολλαπλασιάζονται, λογαριθμοκανονική.
4. Το «τώρα» εξαρτάται από το «πόσο έζησε»; Αν όχι, εκθετική· αν ναι, Weibull με $k \neq 1$.

Παράδειγμα: ο χρόνος ως την τρίτη επανεκπομπή σε κανάλι με σταθερό ρυθμό σφαλμάτων. Είναι χρόνος, άρα θετικός: όχι κανονική. Είναι αναμονή για το τρίτο γεγονός με σταθερό ρυθμό: Gamma με $k = 3$.

Σύνοψη

Διακριτός και συνεχής χρόνος, δίπλα δίπλα

Τρεις κατανομές της προηγούμενης διάλεξης έχουν εδώ τη δίδυμή τους: η *ίδια* ερώτηση, μια φορά πάνω σε σχισμές και μια φορά πάνω σε συνεχή χρόνο.

η ερώτηση	σε σχισμές	σε συνεχή χρόνο
πόσα γεγονότα σε ένα παράθυρο	διωνυμική(n, p)	Poisson(λt)
αναμονή ως το *πρώτο*	γεωμετρική(p)	εκθετική(λ)
αναμονή ως το r-*οστό*	αρν. διωνυμική(r, p)	Gamma(k, λ), $k = r$

Η δεξιά στήλη βγαίνει από την αριστερή αν κόψουμε τη μονάδα χρόνου σε n σχισμές, με $p = \lambda/n$ ανά σχισμή, και αφήσουμε $n \to \infty$: οι σχισμές γίνονται άπειρα λεπτές και εξαφανίζονται.

Τι δείξαμε σήμερα

- Χτίσαμε επτά πρότυπα από τον μηχανισμό τους (την κανονική τη βρήκαμε πειραματικά): ομοιόμορφη, εκθετική, Gamma, Beta, κανονική, λογαριθμοκανονική, Weibull.
- Η **εκθετική** είναι ο χρόνος αναμονής της διαδικασίας Poisson και δεν έχει μνήμη. Η Gamma είναι άθροισμα k ανεξάρτητων εκθετικών.
- Η **λογαριθμοκανονική** βγαίνει από γινόμενα, και η μέση τιμή της είναι $e^{\mu+\sigma^2/2}$, όχι e^{μ}.
- Ο **ρυθμός αστοχίας** είναι σταθερός στην εκθετική και αλλάζει με τον χρόνο στη Weibull. Σε σειρά τα πολλά εξαρτήματα βλάπτουν, παράλληλα ωφελούν.
- Η επιλογή προτύπου κρίνεται από το πεδίο τιμών και από τον μηχανισμό που παράγει τα δεδομένα.

Τι να κρατήσετε

- Η πιθανότητα είναι **εμβαδόν**, όχι ύψος: η πυκνότητα μπορεί να ξεπεράσει το 1.
- Η **εκθετική** είναι η αναμονή της Poisson, με $\mathbb{E}[T] = 1/\lambda$, χωρίς μνήμη.
- Η **κανονική** βγαίνει από αθροίσματα. Με την τυποποίηση αρκεί ένας πίνακας, και σε $\pm\sigma$, $\pm 2\sigma$, $\pm 3\sigma$ πέφτει το 68.27%, το 95.45% και το 99.73%.

Το κοινό νήμα

Δεν διαλέγουμε κατανομή επειδή «ταιριάζει το σχήμα». Τη διαλέγουμε επειδή ο **μηχανισμός** που παράγει τα δεδομένα την επιβάλλει.

Η ομοιόμορφη από την απουσία προτίμησης, η εκθετική και η Gamma από την Poisson, η Beta από άγνωστη πιθανότητα, η κανονική από αθροίσματα, η λογαριθμοκανονική από γινόμενα, και η Weibull από τον **ρυθμό αστοχίας** $h = f/S$, που λέει αν κάτι γερνάει.